Compte rendu du TP 2 : acquisition, stockage et exploitation de données avec Google Colab et SQL

Sujet : Flux financiers du FMI (décaissements et remboursements, 1984-2026)

Travail fait par : LABRAHMI Doha – LAALJ Marwa

1. Introduction : de quoi s'agit-il ?

Ce TP consiste à suivre toute la chaîne de traitement d'un projet d'analyse de données : on part d'un jeu de données public, on le stocke sur Google Drive, on le charge dans Google Colab avec Python (bibliothèque Pandas), on le transforme en base de données SQLite, puis on l'interroge avec des requêtes SQL pour en tirer des conclusions.

Chaîne suivie : Source (FMI) → Téléchargement → Google Drive → Google Colab → Pandas → SQLite → Requêtes SQL → Analyse.

Vocabulaire utile :

- **Dataset** : un tableau de données (lignes = observations, colonnes = variables).
- **Pandas** : bibliothèque Python qui manipule les tableaux de données (DataFrame).
- **SQLite** : une base de données qui tient dans un simple fichier `.db`, sans serveur.
- **SQL** : le langage pour interroger une base (`SELECT` , `WHERE` , `GROUP BY` ...).
- **DTS** : Droits de tirage spéciaux, l'unité de compte du FMI. **Md** = milliards.
- **GRA** : prêts du FMI aux conditions du marché. **PRGT** : prêts concessionnels aux pays à faible revenu. **RST** : guichet récent « résilience et durabilité ».

2. Choix et présentation du dataset

- **Source :** Fonds monétaire international (portail IMF Data, https://www.imf.org/en/Data), tableau « *Past IMF Disbursements and Repayments for all members* » (fichier `extrep1`), téléchargé en Excel.
- **Domaine :** finance internationale (prêts du FMI à ses pays membres et remboursements).

- **Taille** : 43 observations (une par année, de 1984 à 2026) et 13 variables (l'année + 12 montants en DTS). Une variable catégorielle, la **décennie**, a été créée.
- **Particularité** : l'année 2026 est partielle (jusqu'au 30 septembre 2026).
- **Justification** : thème économique et financier, données publiques et gratuites, format Excel, et possibilité d'agrégations SQL variées. Le fichier compte moins de 100 observations, ce qui est accepté « sauf justification » : c'est une série temporelle annuelle qui résume tous les pays membres sur 40 ans.
- **Analyses possibles** : années de pic de prêts, flux net par décennie, poids des prêts concessionnels, poids du coût du crédit.

3. Stockage sur Google Drive et chargement dans Colab

Étapes réalisées : création du dossier `TP_SQL_Dataset` sur Google Drive, dépôt du fichier `extrep1_xls.xlsx`, ouverture d'un notebook Colab, puis montage de Drive avec le code ci-dessous. Le fichier est ensuite vérifié (message d'erreur s'il est introuvable) avant d'être lu.

```
from google.colab import drive
drive.mount('/content/drive')
DOSSIER = Path('/content/drive/MyDrive/TP_SQL_Dataset')
FICHIER = DOSSIER / 'extrep1_xls.xlsx'
if not FICHIER.is_file():
    raise FileNotFoundError(f'Fichier introuvable : {FICHIER}')
```

4. Exploration et préparation des données (Pandas)

4.1 Problèmes rencontrés dans le fiichier

1. **Structure** : 3 lignes de titre, puis un en-tête sur deux niveaux (guichet, puis type de flux). Solution : sauter les 6 premières lignes et donner nos propres noms de colonnes (`gra_decaissements`, `prgt_remboursements`, etc.).
2. **Type des données** : les montants étaient lus comme du texte avec des virgules (`'7,357,252,000'`). Solution : supprimer les virgules et convertir en nombres entiers.
3. **Anomalie** : pour 2010 et 2026, les intérêts PRGT valaient `541.121` et `37.704` au lieu de 541 121 et 37 704 (le séparateur de milliers a été pris pour une virgule décimale). Détection : les colonnes « Total » du FMI doivent être égales à la somme des trois

guichets ; seules ces deux lignes ne respectaient pas la règle. Correction : valeur recalculée à partir du total officiel, puis re-vérification (écart nul partout).

4.2 Résultats de l'exploration

- **Dimensions :** 43 lignes, 14 colonnes (après ajout de `decennie`).
- **Valeurs manquantes** : aucune. **Doublons** : aucun (43 années distinctes).
- **Colonne constante :** `rst_remboursements` vaut 0 pour toutes les années (le guichet RST est trop récent), elle n'apporte donc aucune information.
- **Statistiques** : décaissements totaux moyens de 13,26 Md DTS par an, de 1,29 Md (minimum) à 36,96 Md (maximum).
- **Transformation finale :** ajout de la variable `decennie` (1980s, 1990s, 2000s, 2010s, 2020s) avec `df['decennie'] = (df['annee'] // 10 * 10).astype(str) + 's'`. Les décennies ont des durées inégales : 6 années pour les années 1980 (1984-1989) et 7 pour les années 2020 (jusqu'en 2026).

5. Création de la base SQLite

- `sqlite3` crée et interroge la base ; `pandas` charge les données et lit le résultat des requêtes (`read_sql_query`) ; la méthode `to_sql()` écrit un DataFrame dans une table.
- Une table `fmi_flux` a été créée avec des types adaptés (`INTEGER` , `TEXT`) et l'année comme **clé primaire**, puis remplie avec `to_sql(..., if_exists='append')` .
- **Vérification :** 43 lignes importées, soit autant que dans le DataFrame. Base obtenue : `fmi_flux.db` .

6. Les 15 requêtes SQL et leurs résultats

Niveau 1 : requêtes fiondamentales

1. **Afficher toutes les observations.**

```
SELECT * FROM fmi_flux;
```

Résultat : 43 lignes, 14 colonnes.

2. **Sélectionner certaines colonnes.**

```
SELECT annee, total_decaissements, total_remboursements FROM fmi_flux;
```

Résultat : 43 lignes, 3 colonnes.

3. **Limiter le nombre de résultats (10 années les plus récentes).**

```
SELECT annee, total_decaissements FROM fmi_flux ORDER BY annee DESC LIMIT 10;
```

Résultat : les années 2026 à 2017.

4. **Trier : les 5 années de plus gros décaissements.**

```
SELECT annee, ROUND(total_decaissements/1e9, 2) AS decaissements_Md_DTS
FROM fmi_flux ORDER BY total_decaissements DESC LIMIT 5;
```

Résultat : 2020 (36,96 Md), 2011 (34,56), 2022 (27,33), 2002 (26,58), 2018 (25,45).

5. **Filtrer avec WHERE : décaissements supérieurs à 20 Md DTS.**

```
SELECT annee, ROUND(total_decaissements/1e9, 2) AS decaissements_Md_DTS
FROM fmi_flux WHERE total_decaissements > 20e9 ORDER BY annee;
```

Résultat : 13 années, de 1998 (21,48 Md) à 2025.

Niveau 2 : agrégations

6. **Nombre d'enregistrements.**

```
SELECT COUNT(*) AS nb_annees FROM fmi_flux;
```

Résultat : 43.

7. **Moyennes.**

```
SELECT ROUND(AVG(total_decaissements)/1e9, 2) AS moy_decaissements_Md,
       ROUND(AVG(total_remboursements)/1e9, 2) AS moy_remboursements_Md
FROM fmi_flux;
```

Résultat : 13,26 Md de décaissements et 11,21 Md de remboursements par an en moyenne.

8. **Minimum et maximum.**

```
SELECT ROUND(MIN(total_decaissements)/1e9, 2) AS min_Md,
       ROUND(MAX(total_decaissements)/1e9, 2) AS max_Md,
       MIN(annee) AS premiere_annee, MAX(annee) AS derniere_annee
FROM fmi_flux;
```

Résultat : minimum 1,29 Md, maximum 36,96 Md, période 1984-2026.

9. Regrouper avec GROUP BY : totaux par décennie.

```
SELECT decennie, COUNT(*) AS nb_annees,
       ROUND(SUM(total_decaissements)/1e9, 1) AS decaissements_Md,
       ROUND(SUM(total_remboursements)/1e9, 1) AS remboursements_Md
FROM fmi_flux GROUP BY decennie ORDER BY decennie;
```

Décennie	Années	Décaissé (Md)	Remboursé (Md)
1980s	6	24,1	34,1
1990s	10	104,2	71,3
2000s	10	128,0	143,2
2010s	10	163,1	131,9
2020s	7	151,0	101,4

10. Filtrer les groupes avec HAVING : décennies dont la moyenne annuelle dépasse 10 Md.

```
SELECT decennie, ROUND(AVG(total_decaissements)/1e9, 2) AS moy_Md
FROM fmi_flux GROUP BY decennie
HAVING AVG(total_decaissements) > 10e9 ORDER BY moy_Md DESC;
```

Résultat : 2020s (21,58), 2010s (16,31), 2000s (12,80), 1990s (10,42). Les années 1980 (4,01) sont exclues.

Niveau 3 : analyses avancées

11. AND / OR : forts prêts GRA et PRGT, ou usage du RST.

```
SELECT annee, ROUND(gra_decaissements/1e9,1) AS gra_Md,
       ROUND(prgt_decaissements/1e9,1) AS prgt_Md,
       ROUND(rst_decaissements/1e9,1) AS rst_Md
FROM fmi_flux
WHERE (gra_decaissements > 15e9 AND prgt_decaissements > 2e9)
   OR rst_decaissements > 0
ORDER BY annee;
```

Résultat : 5 années (2020, 2023, 2024, 2025, 2026).

12. BETWEEN et IN : crise financière (2008-2012) et années 2020-2022.

```
SELECT annee, ROUND(total_decaissements/1e9,1) AS decaissements_Md,
       ROUND(total_remboursements/1e9,1) AS remboursements_Md
FROM fmi_flux
WHERE annee BETWEEN 2008 AND 2012 OR annee IN (2020, 2021, 2022)
ORDER BY annee;
```

Résultat : 8 années. Les décaissements dépassent largement les remboursements en 2008-2011 et en 2020 ; en 2021 et 2022 les remboursements augmentent nettement (11,1 puis 18,6 Md).

13. Classement : les 10 plus forts flux nets (décaissements moins remboursements), avec RANK().

```
SELECT RANK() OVER (ORDER BY total_decaissements - total_remboursements DESC)
AS rang,
       annee, ROUND((total_decaissements - total_remboursements)/1e9, 2) AS
flux_net_Md
FROM fmi_flux ORDER BY rang LIMIT 10;
```

Résultat : 1er 2020 (+32,35 Md), 2e 2011 (+32,15), 3e 2009 (+20,81), puis 2010, 2018, 1998, 2019, 2008, 1995, 2001.

14. Sous-requête : années au-dessus de la moyenne des décaissements.

```
SELECT annee, ROUND(total_decaissements/1e9, 2) AS decaissements_Md
FROM fmi_flux
WHERE total_decaissements > (SELECT AVG(total_decaissements) FROM fmi_flux)
ORDER BY annee;
```

Résultat : 19 années sur 43 dépassent la moyenne de 13,26 Md.

15. Analyse synthétique : qui est prêteur net, quelle part de prêts concessionnels, quel poids du coût du crédit ?

```
SELECT decennie,
       ROUND(SUM(total_decaissements)/1e9, 1) AS decaisse_Md,
       ROUND(SUM(total_remboursements)/1e9, 1) AS rembourse_Md,
       ROUND((SUM(total_decaissements) - SUM(total_remboursements))/1e9, 1)
AS flux_net_Md,
       ROUND(100.0 * SUM(prgt_decaissements + rst_decaissements) /
SUM(total_decaissements), 1) AS part_concessionnel_pct,
       ROUND(100.0 * SUM(total_frais_interets) / SUM(total_remboursements +
total_frais_interets), 1) AS part_cout_credit_pct
FROM fmi_flux GROUP BY decennie ORDER BY decennie;
```

Décennie	Décaissé (Md)	Remboursé (Md)	Flux net (Md)	Part concessionnelle (%)	Part coût du crédit (%)
1980s	24,1	34,1	−10,0	7,7	27,6
1990s	104,2	71,3	+32,8	7,2	20,9
2000s	128,0	143,2	−15,2	6,1	10,4
2010s	163,1	131,9	+31,2	5,3	11,1
2020s	151,0	101,4	+49,6	21,0	21,2

7. Analyse et interprétation

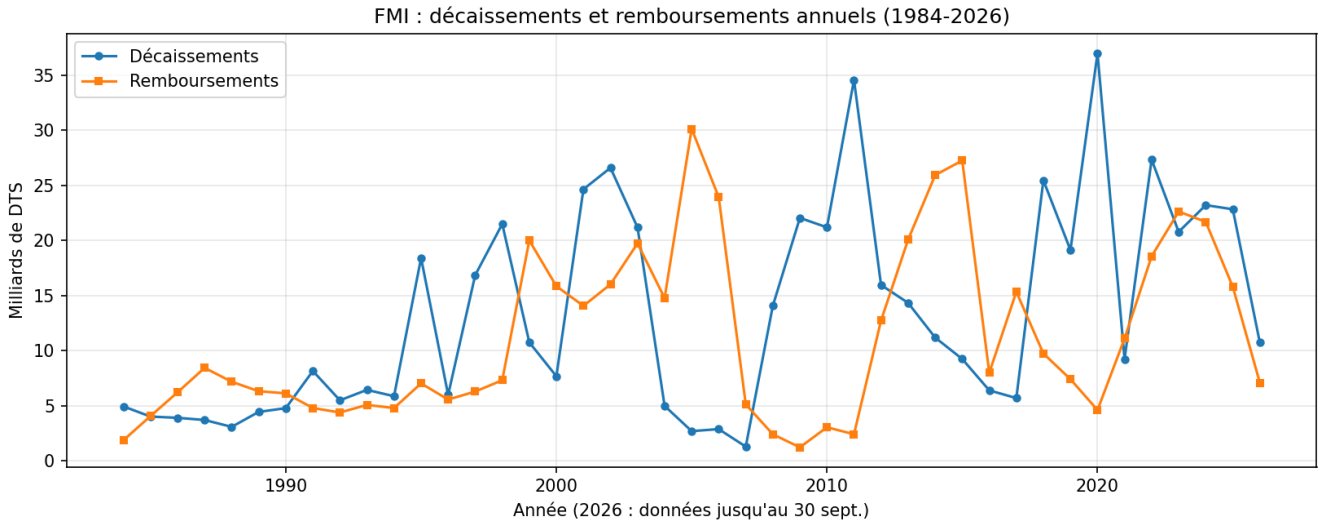
Cinq requêtes sont retenues pour l'analyse : Q4, Q9, Q13, Q14 et Q15.

- **Q4 : pics de décaissement.** Les plus fortes années (2020, 2011, 2022, 2002, 2018) montrent que le FMI prête surtout en période de crise. 2011 et 2020 coïncident avec les suites de la crise financière de 2008 et avec la pandémie de Covid-19.
- **Q9 : par décennie.** Les décaissements cumulés augmentent de décennie en décennie jusqu'aux années 2010. Les années 2020 ont déjà atteint 151 Md en 7 ans : le rythme annuel moyen (21,6 Md) est le plus élevé de la série.
- **Q13 : flux net.** 2020, 2011 et 2009 sont les années où les emprunteurs ont reçu le plus de ressources nettes : ce sont des années de transfert net du FMI vers les pays membres.

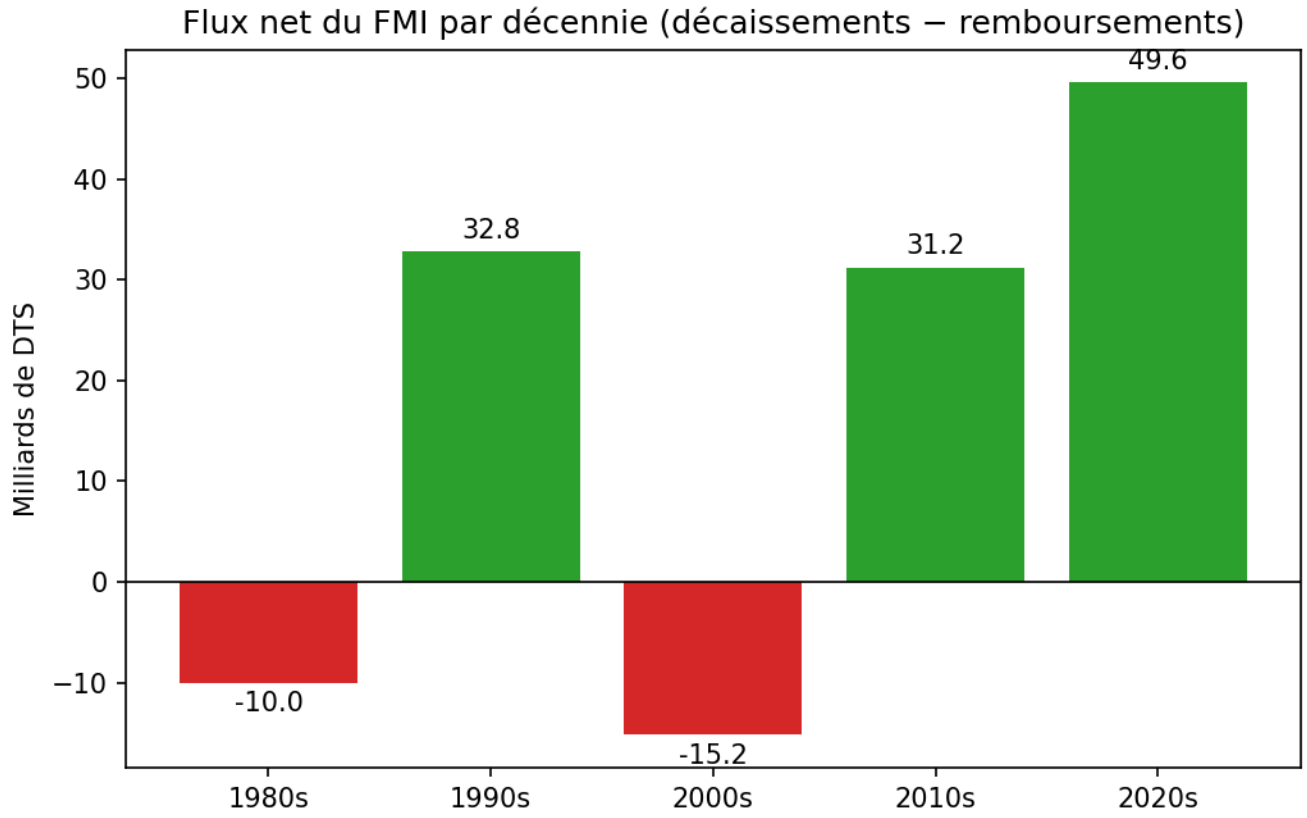
- **Q14 : au-dessus de la moyenne.** 44 % des années dépassent la moyenne, regroupées en trois épisodes : 1995-2003, 2008-2013 et 2018-2025. Les décaissements arrivent par vagues, pas de façon régulière.
- **Q15 : synthèse.** Prêteur net dans les années 1990, 2010 et 2020, récepteur net dans les années 1980 et 2000 (pic de 30,1 Md remboursés en 2005). La part des prêts concessionnels passe de 5,3 % à 21,0 % dans les années 2020, et le coût du crédit pèse 21,2 % des sorties des emprunteurs contre 10-11 % dans les années 2000-2010.

Graphiques

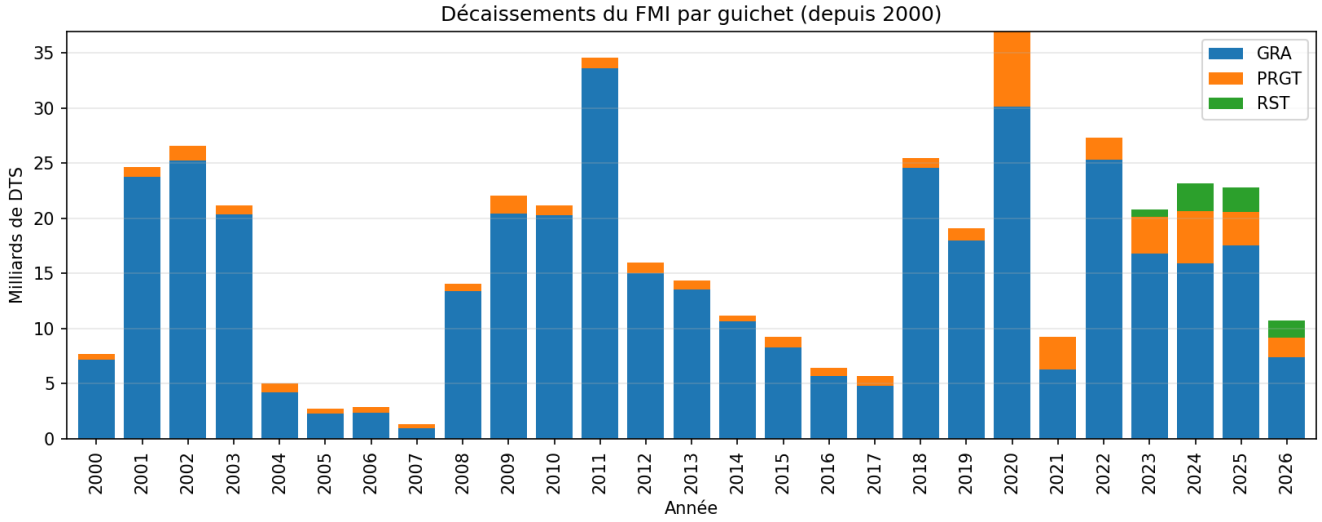
Graphique 1 : décaissements et remboursements annuels (1984-2026). Les deux courbes sont très volatiles : les décaissements culminent en 2011 et 2020, les remboursements en 2005 (30,1 Md) puis en 2014-2015.



Graphique 2 : flux net du FMI par décennie. Vert : le FMI a plus prêché qu'il n'a reçu (années 1990, 2010, 2020) ; rouge : l'inverse (années 1980 et 2000). Les années 1980 (6 ans) et 2020 (7 ans) sont incomplètes.



Graphique 3 : décaissements par guichet depuis 2000. Le GRA domine presque toutes les années ; le PRGT ressort en 2020 (6,8 Md) et le RST n'apparaît qu'à partir de 2023.



8. Conclusions

1. **Le FMI intervient par vagues, surtout en période de crise.** Les décaissements annuels varient de 1,3 à 37,0 Md DTS, avec des pics en 2011 et 2020.

2. **Le rôle de prêteur net n'est pas permanent.** Le flux net est positif dans les années 1990, 2010 et 2020, négatif dans les années 1980 et 2000 quand les remboursements dépassent les nouveaux prêts.
3. **Les années 2020 marquent un changement de structure.** Rythme de prêt le plus élevé, part des guichets concessionnels multipliée par quatre (5,3 % à 21,0 %), et coût du crédit en hausse (record de 6,03 Md de frais payés en 2024).

9. Difiiicultés rencontrées

- Fichier Excel mal structuré (titres, double en-tête, nombres en texte) : résolu par le saut de lignes, le renommage et la conversion.
- Deux valeurs mal lues (2010 et 2026) : détectées grâce au contrôle de cohérence entre totaux et sous-totaux, puis corrigées.
- Dataset de 43 lignes seulement et sans variable catégorielle : justifié et complété par la variable `decennie`.
- Comparaison délicate entre décennies de durées inégales et 2026 incomplète : on compare les moyennes annuelles plutôt que les cumuls.

10. Limites

La série est agrégée sur tous les pays membres (on ne sait pas quels pays expliquent les pics), les montants sont nominaux (non corrigés de l'inflation), et le lien avec les crises (2008, Covid-19) est une coïncidence dans le temps, pas une preuve de causalité.

11. Livrables remis

1. Notebook Google Colab : `TP_SQL_FMI.ipynb`
2. Dataset original : `extrep1_xls.xlsx`
3. Base SQLite : `fmi_flux.db`
4. Les 15 requêtes SQL : `requetes_sql.sql` (et résultats dans le notebook)
5. Synthèse d'une page et le présent compte rendu